

Modelo de riesgo crediticio clásico

Mariana Valenzuela Lafarga¹, Lenin Adair Quezada Gómez¹², Raúl Oviedo Magaña³

Instituto Tecnológico y de Estudios Superiores de Occidente, A.C

Abstract—

El riesgo crediticio representa uno de los principales desafíos en la gestión financiera moderna, ya que la correcta identificación de clientes con alta probabilidad de incumplimiento es fundamental para la estabilidad de las instituciones que otorgan crédito. Este trabajo presenta el desarrollo de un modelo de scoring crediticio interpretable, inspirado en la metodología del Z-Score de Altman, construido a partir de un dataset de 100,000 observaciones mensuales correspondientes a 12,500 clientes. El proceso inició con una etapa exhaustiva de limpieza y verificación de datos, en la que se corrigieron inconsistencias estructurales, valores imposibles y datos faltantes mediante estrategias estadísticamente fundamentadas. Posteriormente, se realizó una transformación de variables mediante la construcción de ratios financieros que eliminan problemas de escala y capturan relaciones económicas relevantes. La variable objetivo se definió de forma binaria, distinguiendo entre clientes en incumplimiento y clientes solventes. Los pesos del modelo no fueron estimados mediante algoritmos de aprendizaje supervisado, sino a través de tres métodos de optimización numérica: Monte Carlo, Evolución Diferencial y Recocido Dual. El modelo seleccionado alcanzó una exactitud del 77.8% y un área bajo la curva ROC de 0.75 en el conjunto de prueba, superando el desempeño base y manteniendo plena interpretabilidad económica. Los resultados sugieren que es posible construir modelos de riesgo crediticio robustos y transparentes sin recurrir a técnicas de aprendizaje automático.

I. INTRODUCCIÓN

El crédito es uno de los mecanismos fundamentales del sistema financiero moderno. A través de él, las instituciones financieras asignan capital a individuos y empresas, habilitando el consumo, la inversión y el crecimiento económico. Sin embargo, esta función conlleva un riesgo inherente: la posibilidad de que el deudor no cumpla con sus obligaciones de pago, evento conocido como default o incumplimiento crediticio. La correcta identificación y cuantificación de este riesgo no solo protege la solvencia de las instituciones prestamistas, sino que también contribuye a la estabilidad del sistema financiero en su conjunto.

Durante décadas, la industria financiera ha desarrollado herramientas cuantitativas para evaluar la probabilidad de incumplimiento de sus clientes. Entre los modelos más influyentes se encuentra el Z-Score de Altman, propuesto en 1968, que introdujo la idea de construir un índice de riesgo como combinación lineal de ratios financieros con coeficientes fijos e interpretables. Este enfoque marcó un parteaguas en la evaluación crediticia corporativa al demostrar que variables contables relativamente simples podían discriminar con alta precisión entre empresas solventes y empresas en quiebra. La elegancia del modelo radica precisamente en su transparencia: cada variable contribuye al score de forma aditiva y su impacto puede cuantificarse e interpretarse directamente.

Con el avance del aprendizaje automático, surgieron modelos de mayor complejidad como los bosques aleatorios, las redes neuronales y los métodos de boosting, los cuales han mostrado capacidades predictivas superiores en múltiples benchmarks. No obstante, su adopción en el ámbito del crédito minorista enfrenta obstáculos importantes. Las regulaciones financieras en numerosas jurisdicciones, como el Reglamento General de Protección de Datos en Europa o las directrices del Consumer Financial Protection Bureau en Estados Unidos, exigen que las decisiones crediticias sean explicables y auditables. Un modelo de caja negra que clasifica a un cliente como de alto riesgo sin poder justificar los factores que determinaron esa decisión resulta difícil de defender ante reguladores, comités de riesgo o los propios clientes afectados. Esta tensión entre capacidad predictiva e interpretabilidad constituye uno de los problemas más activos en la literatura actual de riesgo crediticio.

El presente trabajo aborda este problema mediante el desarrollo de un modelo de scoring crediticio lineal e interpretable aplicado a una base de datos de 100,000 observaciones mensuales correspondientes a 12,500 clientes individuales. El modelo sigue la lógica estructural del Z-Score de Altman, adaptada al contexto del crédito al consumo: se construye como una suma ponderada de ratios financieros cuyo signo se fija por teoría económica y cuyos pesos se determinan mediante búsqueda numérica, sin recurrir en ningún momento a algoritmos de entrenamiento supervisado como la regresión logística o métodos de machine learning. Esta decisión metodológica no es una limitación, sino una elección deliberada orientada a garantizar la interpretabilidad, la estabilidad fuera de muestra y la coherencia económica del modelo.

El proceso metodológico se organiza en cuatro etapas. En primer lugar, se realiza una limpieza exhaustiva del dataset, corrigiendo inconsistencias estructurales, valores imposibles y datos faltantes en múltiples variables mediante estrategias adaptadas a la naturaleza de cada campo. En segundo lugar, se lleva a cabo una verificación estadística y económica del dataset resultante para garantizar su idoneidad para modelado. En tercer lugar, se construyen variables derivadas mediante ingeniería de características, transformando variables absolutas en ratios financieros que eliminan problemas de escala y capturan relaciones económicas relevantes. Finalmente, se optimizan los pesos del modelo mediante tres métodos de búsqueda numérica: simulación Monte Carlo, Evolución Diferencial y Recocido Dual, seleccionando el modelo final con base en su desempeño en un conjunto de validación independiente.

Las contribuciones principales de este trabajo son las siguientes:

1. Un protocolo detallado y reproducible de limpieza de datos crediticios con estrategias diferenciadas por variable, incluyendo imputación por moda intracliente, forward fill temporal, winsorización por percentiles y detección de valores estructuralmente inválidos.
2. La construcción de un conjunto de ratios financieros inspirados en el enfoque de Altman, adaptados al crédito al consumo y justificados tanto estadística como económicamente.
3. Un marco de optimización de pesos sin entrenamiento supervisado que combina tres métodos numéricos y selecciona el modelo por desempeño en validación, evitando data leakage.
4. Un modelo final con accuracy de 77.8% y ROC-AUC de 0.75 en el conjunto de prueba, que mantiene interpretabilidad completa y calibración adecuada de la tasa de default predicha.

II. MARCO TEORICO

2.1 Riesgo Crediticio y la Necesidad de Modelos de Scoring

El riesgo crediticio se define como la posibilidad de que una contraparte no cumpla con sus obligaciones financieras en los términos y plazos pactados. En el contexto del crédito al consumo, este riesgo se materializa cuando un cliente deja de realizar los pagos correspondientes a sus préstamos, tarjetas de crédito u otras obligaciones, evento que se denomina default o incumplimiento. La gestión de este riesgo es central para la operación de cualquier institución financiera, ya que las pérdidas derivadas del incumplimiento afectan directamente la rentabilidad, la liquidez y la solvencia del acreedor.

Para cuantificar y anticipar este riesgo, las instituciones financieras utilizan modelos de scoring crediticio: herramientas cuantitativas que asignan a cada cliente un valor numérico que resume su perfil de riesgo. Un score alto indica mayor probabilidad de incumplimiento, mientras que un score bajo señala un perfil financiero más sólido. Estos modelos permiten estandarizar y escalar el proceso de evaluación crediticia, reduciendo la subjetividad en la toma de decisiones y facilitando la segmentación de clientes en categorías operativas de riesgo.

2.2 El Modelo Z-Score de Altman como Referencia Metodológica

El antecedente más influyente en la construcción de scores crediticios lineales es el modelo Z-Score propuesto por Edward Altman en 1968 para la predicción de quiebras empresariales. Su formulación es la siguiente:

$$Z = 1.2 x_1 + 1.4 x_2 + 3.3 x_3 + 0.6 x_4 + 1.0 x_5$$

Variable	Definición
x1	Capital de trabajo / Activos totales
x2	Utilidades retenidas / Activos totales
x3	EBIT / Activos totales
x4	Valor de mercado del patrimonio / Pasivos totales
x5	Ventas / Activos totales

La contribución fundamental del modelo de Altman no reside únicamente en su precisión predictiva, sino en su arquitectura metodológica. Al construir el score como una combinación lineal de ratios —y no de valores absolutos— el modelo elimina

el problema de escala entre variables de distinta magnitud, permite comparar entidades de diferentes tamaños y mantiene interpretabilidad directa: cada coeficiente w_i expresa el impacto marginal de un cambio unitario en la ratio correspondiente sobre el score de riesgo. Este principio es el que inspira el modelo desarrollado en el presente trabajo, adaptado al contexto del crédito al consumo individual.

2.3 Ratios Financieros como Variables de Entrada

Un ratio financiero es una relación entre dos magnitudes económicas que captura una dimensión específica del comportamiento financiero de un agente. A diferencia de las variables en niveles absolutos, las ratios son adimensionales o están expresados en unidades homogéneas, lo que los hace comparables entre individuos con distintos niveles de ingreso, deuda o patrimonio.

En el contexto de un modelo lineal del tipo:

$$Z = \sum_{j=1}^k w_j X_j$$

el uso de variables absolutas genera un sesgo por escala: variables con mayor magnitud numérica dominan el resultado independientemente de su contenido informativo. Este problema se evita construyendo ratios que normalizan cada variable por una referencia económicamente relevante. Por ejemplo, el nivel de deuda de un cliente solo es interpretable en relación con su ingreso; una deuda de 50,000 representa un riesgo muy distinto para alguien que gana 30,000 anuales que para alguien que gana 500,000. El ratio deuda-ingreso captura esta relación de forma directa y comparable.

Adicionalmente, los ratios presentan la ventaja de ser calculables directamente sobre cualquier cliente nuevo sin depender de estadísticas del conjunto de entrenamiento, como medias o desviaciones estándar. Esto garantiza la estabilidad del score fuera de muestra y su aplicabilidad operativa en tiempo real.

2.4 Definición Binaria del Default y Variable Objetivo

Siguiendo la lógica de los modelos clásicos de riesgo, el problema de clasificación se formula en términos binarios. La variable objetivo Y se define como:

$$Y_i = \begin{cases} 1 & \text{Si el cliente } i \text{ presenta un perfil de alto riesgo (Poor)} \\ 0 & \text{Si el cliente } i \text{ presenta un perfil normal o bueno} \end{cases}$$

Esta binarización permite tratar el problema como una clasificación de default versus no default, concentrando el poder discriminante del modelo en la distinción más relevante desde el punto de vista de la gestión del riesgo. La segmentación en categorías adicionales —good, standard— puede recuperarse posteriormente mediante umbrales sobre el score continuo, tal como lo propone la metodología de Altman con sus zonas gris y segura.

2.5 Restricciones Económicas sobre los Pesos

Una característica distintiva del enfoque adoptado es que los signos de los coeficientes w_j se fijan a priori con base en la teoría de riesgo crediticio, antes de iniciar cualquier procedimiento de optimización. Esta decisión responde a dos motivaciones complementarias.

La primera es de naturaleza económica: la dirección del efecto de cada variable sobre el riesgo de default es conocida con anterioridad. Una mayor tasa de ahorro reduce el riesgo; un mayor estrés por intereses lo incrementa. Permitir que el algoritmo de optimización invierta estos signos produciría coeficientes contraintuitivos que, aunque pudieran mejorar marginalmente la métrica en la muestra de entrenamiento, carecerían de interpretación económica válida y serían difíciles de defender ante auditores o comités de riesgo.

La segunda motivación es de naturaleza estadística: fijar los signos reduce el espacio de búsqueda de parámetros, haciendo la optimización más eficiente y disminuyendo el riesgo de sobreajuste. Formalmente, si $u_j \geq 0$ representa la magnitud del peso para la variable j , el peso final se define como:

$$w_j = \text{signo}_j \cdot u_j$$

donde $\text{signo} \in \{-1, +1\}$ es fijado por teoría y u_j es la magnitud optimizada numéricamente.

2.6 Regla de Decisión por Umbral Proporcional

Una vez calculado el score $Z_i = \sum_j w_j x_{ij}$ para cada cliente, la clasificación se realiza mediante un umbral T definido de forma proporcional a la tasa de default observada en el conjunto de entrenamiento. $p=P(Y=1)$ es la tasa de incumplimiento, el umbral se define como:

$$T = Q_{1-p}(Z)$$

es decir, el cuantil de la distribución del score en entrenamiento. La regla de decisión es entonces:

$$Y_i = \begin{cases} 1 & \text{si } Z_i \geq T \\ 0 & \text{si } Z_i < T \end{cases}$$

Este mecanismo garantiza que la proporción de clientes clasificados como default en entrenamiento coincida con la tasa real observada, preservando la calibración del modelo a nivel agregado. Es una alternativa a la búsqueda libre del umbral óptimo que evita sobre ajustar el punto de corte al conjunto de entrenamiento.

2.7 Métodos de Optimización Numérica

El problema de encontrar los pesos óptimos del score crediticio presenta una característica que lo distingue de los problemas de optimización clásicos en estadística: la función objetivo —la exactitud de clasificación— es discontinua y no diferenciable con respecto a los pesos.

Esto ocurre porque la exactitud depende de comparaciones discretas entre el score y un umbral. Formalmente:

$$\text{Accuracy}(w) = (1/n) \cdot \sum_i 1[\hat{Y}_i(w) = Y_i] \quad (1)$$

Donde el accuracy vale 1 si la predicción es correcta y 0 en caso contrario. Un cambio infinitesimal en los pesos w puede no modificar ninguna predicción, o puede cambiar varias simultáneamente de forma abrupta cuando el score de algún cliente cruza el umbral T . Por esta razón, el gradiente $\nabla_w \text{Accuracy}$ no existe en la mayoría de los puntos, haciendo inaplicables métodos clásicos como:

- Descenso por gradiente (Gradient Descent)
- Adam / RMSProp
- L-BFGS-B
- Newton-Raphson

Se recurre entonces a tres métodos de búsqueda numérica que no requieren diferenciabilidad y operan directamente sobre evaluaciones de la función objetivo. En los tres casos, los pesos están acotados por variable mediante límites derivados del rango intercuartílico del subtrain:

$$u_j^{\max} = \min(C / (P_{95^{(j)}} - P_{5^{(j)}}), 10.0) \quad (2)$$

donde $C = 2.0$ es el impacto máximo permitido por variable en su rango típico y $P_{5^{(j)}}$, $P_{95^{(j)}}$ son los percentiles 5 y 95 de la variable j en el subtrain. Este mecanismo de acotamiento evita que ninguna variable domine el score por efecto de escala residual, sin requerir estandarización de los datos.

2.7.1 Simulación Monte Carlo

La simulación Monte Carlo es el método más directo conceptualmente. Su principio es simple: si el espacio de parámetros está acotado, es posible explorarlo generando combinaciones aleatorias de pesos y evaluando la función objetivo en cada una, conservando únicamente la mejor solución encontrada.

Procedimiento

1. Fijar los límites de búsqueda por variable: $u_j \in [0, u_j^{\max}]$ según la ecuación (2).
2. Generar $N = 50,000$ vectores de magnitudes $u = (u_1, \dots, u_7)$ mediante muestreo uniforme independiente por variable: $u_j \sim \text{Uniforme}(0, u_j^{\max})$ para $j = 1, \dots, 7$ (3)
3. Para cada vector construir los pesos finales aplicando los signos fijados por teoría: $w = u \odot \text{signos}$ donde $\text{signo}_j \in \{-1, +1\}$ (4)
4. Calcular el score sobre el subtrain: $s = X_{\text{sub}} \cdot w$
5. Determinar el umbral proporcional $T = Q_{(1-p)}(s)$ y evaluar la exactitud en validación.
6. Conservar el vector $u^* = \text{argmax Accuracy_val}(u)$.

Propiedades

Propiedad	Descripción
Cobertura	Con 50,000 iteraciones y 7 variables, el espacio es muestreado densamente
Reproducibilidad	Completamente determinista dado un estado inicial fijo (<code>random_seed = 42</code>)
Paralelizable	Cada evaluación es independiente, permite ejecución distribuida
Limitación	No aprovecha información de evaluaciones anteriores para guiar la búsqueda

2.7.2 Evolución Diferencial

La Evolución Diferencial (DE) es un algoritmo metaheurístico poblacional diseñado para optimización global en espacios continuos con funciones objetivo no diferenciables o multimodales. A diferencia de Monte Carlo, aprende de las evaluaciones pasadas y guía la búsqueda de forma adaptativa.

El algoritmo opera sobre una población de $NP = 20$ vectores solución que evolucionan durante un máximo de 300 generaciones. Cada generación aplica tres operaciones secuenciales sobre cada individuo de la población:

Operación 1 — Mutación

Para cada vector objetivo u_i de la población, se construye un vector mutante v_i . En la estrategia `best1bin` utilizada, el mejor vector actual de la población u_{best} actúa como base:

$$v_i = u_{\text{best}} + F \cdot (u_{r2} - u_{r3}) \quad (5)$$

donde $r2, r3$ son índices aleatorios distintos de i y F es el factor de escala de mutación. Al usar u_{best} como base, la búsqueda converge hacia la mejor región conocida mientras que la diferencia $(u_{r2} - u_{r3})$ aporta diversidad exploratoria.

Operación 2 — Cruce

Se genera un vector de prueba t_i combinando componente a componente el vector objetivo u_i y el vector mutante v_i con probabilidad de cruce CR :

$$t_{i,j} = v_{i,j} \text{ si } \text{rand}() \leq CR \quad (\text{acepta mutante}) \quad (6a)$$

$$t_{i,j} = u_{i,j} \text{ si } \text{rand}() > CR \quad (\text{conserva original}) \quad (6b)$$

Al menos un componente siempre toma el valor del mutante, garantizando que $t_i \neq u_i$.

Operación 3 — Selección

El vector de prueba t_i reemplaza al vector objetivo u_i en la siguiente generación únicamente si mejora la función objetivo:

$$u_i^{(t+1)} = t_i \quad \text{si } f(t_i) \leq f(u_i) \quad (7a)$$

$$u_i^{(t+1)} = u_i \quad \text{en otro caso} \quad (7b)$$

Este mecanismo garantiza que la población mejore monótonicamente a lo largo de las generaciones: ningún individuo puede ser reemplazado por uno peor.

Hiperparámetros utilizados

Hiperparámetro	Valor	Descripción
Estrategia	best1bin	Mutación basada en el mejor individuo + cruce binario
Tamaño de población (NP)	20	Número de vectores solución simultáneos
Máx. generaciones	300	Iteraciones máximas del algoritmo evolutivo
Tolerancia (tol)	0.0	Sin parada prematura por convergencia
Polish	False	No se aplica refinamiento local final (L-BFGS-B incompatible)
Workers	1	Ejecución secuencial para reproducibilidad

2.7.3 Recocido Dual

El Recocido Dual (Dual Annealing) es una variante avanzada del recocido simulado clásico que combina dos estrategias complementarias: exploración global mediante visitas generalizadas y refinamiento local mediante búsqueda acelerada. Su nombre hace referencia a que opera con dos procesos de enfriamiento simultáneos.

Analogía Física

La motivación del algoritmo proviene de la metalurgia: cuando un metal fundido se enfría lentamente, sus átomos tienen tiempo de reorganizarse en la configuración de mínima energía, produciendo una estructura cristalina ordenada. Si el enfriamiento es demasiado rápido, los átomos quedan atrapados en configuraciones subóptimas —óptimos locales—. El algoritmo replica este proceso en el espacio de parámetros, donde la 'energía' corresponde al negativo de la función objetivo.

Mecanismo de Aceptación Probabilística

El elemento central que distingue al Recocido Dual de la Evolución Diferencial es su capacidad de aceptar temporalmente soluciones peores. Dado un deterioro $\Delta F > 0$ en la función objetivo, la probabilidad de aceptar la solución peor es:

$$P(\text{aceptar solución peor}) = \exp(-\Delta F / T_{\text{actual}}) \quad (8)$$

donde T_{actual} es la temperatura actual del sistema. Esta probabilidad tiene dos propiedades clave:

- Cuando T_{actual} es alta (inicio): $\exp(-\Delta F/T) \approx 1$, se aceptan soluciones peores con alta frecuencia → exploración amplia del espacio.
- Cuando T_{actual} es baja (final): $\exp(-\Delta F/T) \approx 0$, prácticamente solo se aceptan mejoras → explotación local refinada.

Este mecanismo permite escapar de óptimos locales durante la fase de exploración, algo que la Evolución Diferencial y Monte Carlo no pueden garantizar de igual forma.

Esquema de Enfriamiento

La temperatura disminuye a lo largo de las iteraciones según el esquema de enfriamiento generalizado:

$$T(k) = T_0 \cdot \exp(-c \cdot k^{1/d}) \quad (9)$$

donde k es el número de iteración, d es la dimensión del espacio de búsqueda ($d = 7$ variables), c es la constante de enfriamiento y T_0 es la temperatura inicial. La función exponencial garantiza que la temperatura decrezca suavemente, permitiendo suficiente exploración antes de converger.

Distribución de Visitas Generalizada

A diferencia del recocido simulado clásico que propone nuevas soluciones mediante perturbaciones gaussianas, el Recocido Dual utiliza una distribución de visitas generalizada con colas más pesadas:

$$P_{\text{visita}}(x) \propto (1 + |x|^2/T)^{-d} \quad (10)$$

Esta distribución permite saltos más largos en el espacio de parámetros durante la fase de exploración, aumentando la probabilidad de alcanzar regiones prometedoras alejadas de la solución actual.

Hiperparámetros utilizados

Hiperparámetro	Valor	Descripción
maxiter	7,000	Número máximo de iteraciones del algoritmo
seed	42	Semilla aleatoria para reproducibilidad
Dimensión (d)	7	Número de variables del modelo
Bounds	$[(0, u_j^{\max})]$	Límites por variable según ecuación (2)

2.7.4 Comparación de los Tres Métodos

Los tres métodos abordan el mismo problema desde perspectivas fundamentalmente distintas. La siguiente tabla resume sus características principales:

Característica	Monte Carlo	Evolución Diferencial	Recocido Dual
Tipo	Muestreo aleatorio	Algoritmo poblacional	Trayectoria única
Aprende de evaluaciones previas	No	Sí (población)	Sí (trayectoria)
Puede escapar óptimos locales	Por probabilidad	Limitado	Sí (temperatura)
Acepta soluciones peores	No	No	Sí (prob. decrec.)
Iteraciones / Evaluaciones	50,000	$20 \times 300 = 6,000$	7,000
Reproducibilidad	Total (seed=42)	Total (seed=42)	Total (seed=42)
Complejidad de implementación	Baja	Media	Alta
Más efectivo cuando...	Espacio amplio y uniforme	Función multimodal	Múltiples óptimos locales

En los tres métodos, la función objetivo que se maximiza es la exactitud de clasificación sobre el conjunto de subtrain, el umbral T se calibra proporcionalmente a la tasa de default del subtrain, y la selección del modelo final se realiza con base en el desempeño sobre el conjunto de validación, garantizando que el conjunto de prueba permanezca completamente ajeno al proceso de calibración hasta la evaluación final.

2.7.5 Protocolo Completo de Optimización

El flujo completo de optimización, común a los tres métodos, puede resumirse en el siguiente esquema:

Etapas	Descripción	Conjunto utilizado
1. Acotamiento	Calcular $u_j^{\max} = \min(C/\delta_j, 10.0)$ con $\delta_j = P_{95} - P_5$	Subtrain
2. Búsqueda	Explorar combinaciones de pesos $u \in [0, u_j^{\max}]$	Subtrain

3. Calibración	Para cada u calcular $T = Q_{(1-p)}(X_{\text{sub}} \cdot w)$	Subtrain
4. Evaluación interna	Calcular Accuracy con el umbral T	Subtrain
5. Selección	Guardar u^* que maximiza Accuracy en validación	Validación
6. Evaluación final	Reportar métricas del modelo seleccionado (una sola vez)	Test

Este protocolo garantiza que el conjunto de prueba no participe en ninguna etapa de calibración o selección, asegurando que las métricas finales reportadas sean representativas del desempeño real del modelo fuera de muestra.

2.8 Métricas de Evaluación

El desempeño del modelo se evalúa mediante tres métricas complementarias. La **exactitud** mide la proporción de observaciones correctamente clasificadas y constituye la métrica primaria de optimización. El **área bajo la curva ROC** cuantifica la capacidad del score para discriminar entre clientes en default y clientes solventes a lo largo de todos los posibles umbrales de decisión, siendo independiente del umbral específico elegido. La **estadística KS** mide la máxima separación entre las funciones de distribución acumulada del score para ambas clases, y es ampliamente utilizada en la industria financiera como indicador de poder discriminante de los modelos de scoring.

III. LIMPIEZA Y VERIFICACIÓN DEL DATASET

El objetivo de esta sección es obtener un dataset robusto, consistente y listo para el modelado de crédito. El proceso cubre la conversión de variables al tipo correcto, la identificación y tratamiento de valores inválidos, la imputación de datos faltantes y la generación de variables finales limpias.

En este caso utilizamos un método llamado winsorización

Winsorización

Es una técnica estadística de tratamiento de valores extremos que **no elimina observaciones**, sino que las **reemplaza por un valor límite definido**. Su funcionamiento es el siguiente:

Se elige un percentil de corte, por ejemplo, el percentil 99.9. Todos los valores que superen ese umbral son reemplazados por el valor exacto del percentil, mientras que todos los valores por debajo permanecen intactos.

Formalmente:

$$X_{\text{wins}} = \min(X, P_{99.9})$$

Por ejemplo, si el percentil 99.9 de `Annual_Income` es 21,752,126 y un cliente tiene un ingreso registrado de 24,198,062, ese valor se reemplaza por 21,752,126. El registro no desaparece del dataset, simplemente su valor queda acotado al límite superior establecido.

3.1 Descripción del dataset

El dataset original (`train-3.csv`) contiene 100,000 observaciones y 28 variables que describen el perfil financiero mensual de 12,500 clientes. Cada cliente aparece en 8 registros consecutivos (uno por mes), conformando un panel balanceado. La variable objetivo es `Credit_Score`, con tres categorías: Good, Standard y Poor.

El `df.info()` inicial reveló los siguientes aspectos estructurales:

- 20 de las 28 variables están tipadas como object, requiriendo conversión a numérico.
- Varias variables presentan valores faltantes en distintas proporciones.
- La columna 26 (Monthly_Balance) generó una advertencia de tipos mixtos al importar.

3.2 Metodología general de limpieza

Dado que el modelo objetivo es de tipo lineal clásico (similar al enfoque de Altman), la escala, distribución y estabilidad estadística de las variables numéricas son fundamentales. Se adoptaron las siguientes estrategias de intervención según la naturaleza de cada problema:

- **Conversión de tipo.** Aplicada a variables almacenadas como *object* que contenían valores numéricos. Mediante `pd.to_numeric()` con `errors='coerce'`, los valores no convertibles quedaron reclasificados como NaN automáticamente.
- **Invalidación estructural.** Utilizada ante valores físicamente imposibles, como edades negativas. Al no ser errores de escala sino entradas inválidas por definición, se reclasificaron directamente como NaN.
- **Winsorización.** Aplicada a variables con colas explosivas que inflaban la varianza, como el EMI mensual. Se recortaron los valores por encima del percentil 99 o 99.9 según el caso, sin eliminar observaciones.
- **Majority vote.** Empleado en variables que deberían ser estables por cliente pero presentaban NaN puntuales. Se imputó con la moda calculada dentro de cada Customer_ID.
- **ffill / bfill.** Reservado para variables acumulativas o temporales, como el historial crediticio en meses. El valor del mes anterior o posterior constituye una estimación razonable del dato faltante.
- **Mediana global.** Utilizada en variables dinámicas sin patrón intracliente claro. Se empleó la mediana del conjunto completo como valor de referencia neutro.
- **Imputación contable.** Aplicada exclusivamente a Monthly_Inhand_Salary faltante, imputada como $\text{Annual_Income} / 12$, manteniendo coherencia económica entre ambas variables.

3.3 Resumen de intervenciones

La siguiente tabla consolida todas las variables intervenidas, el problema detectado, el tratamiento aplicado y el porcentaje de filas afectadas.

VARIABLE	PROBLEMA DETECTADO	TRATAMIENTO APLICADO	% FILAS AFECTADAS
Age	Valores imposibles (-500 a 8,698)	Invalidar + moda intracliente + fallback mediana	23.47 %
Annual_Income	Cola explosiva (max 24.2 M)	Winsorización al P99.9	0.10 %
Outstanding_Debt	Sin problemas detectados	Sin intervención	—
Credit_History_Age	Formato texto	Parseo a meses + ffill/bfill	9.03 %
Monthly_Balance	Valores corrupto (-3×10^{26})	Invalidar ($ \text{val} > 10k$) + ffill/bfill	1.21 %
Amount_invested_monthly	Placeholder 10,000 (artificial)	Invalidar 10k + ffill/bfill	8.78 %
Num_of_Loan	Negativos y > 50	Invalidar + moda intracliente	4.33 %
Num_of_Delayed_Payment	Negativos y > 100	Invalidar + moda intracliente	8.37 %
Changed_Credit_Limit	2.09 % NaN	Mediana global	2.09 %
Interest_Rate	Tasas > 100 %	Invalidar + moda intracliente	2.01 %
Num_Credit_Inquiries	Outliers > 50	Invalidar + moda intracliente	1.63 %
Total_EMI_per_month	Cola artificial post P95	Winsorización al P95	5.00 %
Num_Bank_Accounts	Outliers > 50	Invalidar + moda intracliente	1.30 %

Num_Credit_Card	Outliers > 50	Invalidar + moda intracliente	2.21 %
Delay_from_due_date	0.59 % negativos	Invalidar + mediana global	0.59 %
Monthly_Inhand_Salary	15 % faltantes	Imputación contable (income/12)	15.00 %
Credit_Mix	Placeholder '_' (20.2 %)	NaN + moda intracliente + ordinal	20.20 %
Payment_of_Min_Amount	Token 'NM' (12 %)	NaN + moda intracliente + binaria	12.00 %
Payment_Behaviour	Token '!@9#%8' (7.6 %)	NaN + moda global + parseo ordinal	7.60 %
Occupation	Placeholder '_____'	NaN + moda intracliente	~7.06 %

3.4 Dataset final

Tras completar todas las etapas de limpieza, el dataset resultante contiene 25 variables finales más identificadores, sin ningún valor faltante (0.0% NaN global), y fue exportado como `credit_dataset_clean.csv` para su uso en la fase de modelado.

El panel es balanceado: 100,000 filas correspondientes a 12,500 clientes únicos con 8 meses de observación cada uno. No se eliminó ningún registro durante el proceso — todas las intervenciones fueron de imputación o corrección, nunca de descarte.

Todas las variables numéricas están libres de valores estructuralmente imposibles y con varianza estabilizada. Las variables categóricas han sido codificadas de forma ordinal o binaria, preservando su interpretabilidad económica. El dataset está listo para la construcción del modelo de scoring crediticio.

3.5 Descripción de las variables

Identificadores

Variable	Tipo	Descripción	Uso en Modelo
Customer_ID	Identificador	Código único por cliente	No se usa como predictor
Month	Temporal	Mes del registro financiero	Análisis longitudinal

Variable Objetivo

Credit_Score es la clasificación crediticia original con tres categorías:

Categoría	Observaciones	Porcentaje
Standard	53,174	53.17%
Poor	28,998	29.00%
Good	17,828	17.83%

Nota: En el modelo de scoring se transformó Credit_Score en variable binaria: Poor = 1 (default), Standard/Good = 0 (no default). La tasa de default resultante es 28.998%.

Variables Numéricas

A continuación se describen las variables numéricas incluidas en el dataset, agrupadas por categoría económica.

Variable	Tipo	Descripción	Grupo
Age	Discreta	Edad del cliente (18–56 años)	Demográfica
Annual_Income	Continua	Ingreso anual bruto	Ingreso
Monthly_Inhand_Salary	Continua	Ingreso mensual disponible	Ingreso
Outstanding_Debt	Continua	Deuda total pendiente	Endeudamiento
Num_of_Loan	Discreta	Número de préstamos activos	Endeudamiento

Total_EMI_per_month	Continua	Pago mensual total (EMI)	Endeudamiento
Credit_History_Months	Discreta	Antigüedad crediticia (meses)	Historial
Num_of_Delayed_Payment	Discreta	Pagos retrasados	Historial
Delay_from_due_date	Discreta	Días promedio de retraso	Historial
Num_Credit_Inquiries	Discreta	Consultas crediticias recientes	Historial
Credit_Utilization_Ratio	Continua	Proporción de crédito utilizado	Comportamiento
Monthly_Balance	Continua	Saldo promedio mensual neto	Comportamiento
Amount_invested_monthly	Continua	Monto invertido mensualmente	Comportamiento
Num_Bank_Accounts	Discreta	Cuentas bancarias activas	Infraestructura
Num_Credit_Card	Discreta	Tarjetas de crédito activas	Infraestructura
Interest_Rate	Continua	Tasa de interés promedio	Contractual
Changed_Credit_Limit	Continua	Variación en límite de crédito	Contractual

Variables Categóricas Transformadas para Modelado

Las siguientes variables fueron codificadas ordinalmente para su uso en modelos estadísticos:

Variable	Codificación	Significado
Credit_Mix_final	0 / 1 / 2	Bad / Standard / Good
Payment_of_Min_Amount_final	0 / 1	No paga / Sí paga mínimo
Spending_Level_final	0 / 1	Low / High spending
Payment_Size_final	0 / 1 / 2	Small / Medium / Large

3.6 Resultado de la verificación

Los cinco componentes verificados arrojan un resultado favorable en todos los casos:

Integridad numérica: Ninguna de las 17 variables numéricas presenta valores infinitos ni negativos en rangos económicamente inválidos. Los mínimos y máximos son consistentes con la realidad financiera del dataset.

Duplicados estructurales: El dataset no contiene duplicados exactos ni duplicados por la clave compuesta Customer_ID + Month. La tasa de duplicación es 0.00% en ambas verificaciones.

Cardinalidad categórica: Credit_Score presenta exactamente 3 categorías validas y Occupation 15 ocupaciones sin valores corruptos, confirmando la efectividad de la limpieza aplicada en la etapa anterior.

Coherencia económica: Las tres condiciones financieras evaluadas son prácticamente perfectas. El único caso marginal — EMI superior al salario mensual — afecta al 0.008% de las observaciones y no compromete la calidad del dataset.

Correlaciones extremas: La correlación máxima entre variables numéricas es 0.64, muy por debajo del umbral crítico de 0.85. Todas las relaciones identificadas tienen una interpretación económica coherente y no representan multicolinealidad problemática.

IV. EXPLICACIÓN DEL MODELO

4.1 Estructura General del Score

El modelo desarrollado en este trabajo es un score de riesgo crediticio lineal definido como una combinación ponderada de variables financieras:

$$Z = \sum_{j=1}^7 w_j X_j$$

donde X_j representa cada variable financiera incluida en el modelo y W_j su peso asociado. La interpretación del score es directa: un valor alto de Z indica mayor probabilidad de incumplimiento, mientras que un valor bajo corresponde a un perfil financiero más sólido. Esta convención es consistente con la lógica del Z-Score de Altman y permite utilizar el score tanto como clasificador binario —mediante un umbral de decisión— como instrumento de ranking de riesgo para segmentación de clientes.

A diferencia de modelos estimados por regresión logística o métodos de aprendizaje supervisado, los pesos W_j de este modelo no se obtienen minimizando una función de pérdida sobre los datos de entrenamiento. En su lugar, se determinan mediante búsqueda numérica directa en el espacio de parámetros, maximizando la exactitud de clasificación sobre un conjunto de subtrain y seleccionando el modelo final con base en su desempeño sobre un conjunto de validación independiente.

4.2 Variables del Modelo

El modelo final utiliza siete variables, todas ellas construidas como ratios financieros o variables categóricas ordinales derivadas del proceso de limpieza y verificación descrito en la sección anterior. La siguiente tabla presenta cada variable con su fórmula de construcción, el signo asignado y su interpretación económica:

Variable	Fórmula	Signo	Interpretación
R3_log	$\log\left(1 + \frac{\text{Monthly balance}}{\text{Total EMI} + \epsilon}\right)$	(-)	Capacidad de cubrir obligaciones con liquidez disponible. Mayor cobertura implica menor riesgo
Age	-	(-)	Clientes de mayor edad presentan mayor estabilidad financiera y menor probabilidad de incumplimiento
Credit_mix	Codificación ordinal Bad=0, Standard=1, Good=2	(-)	Una mezcla crediticia más diversificada y saludable reduce el riesgo percibido
Payment Size	Codificación ordinal: Small=0, Medium=1, Large=2	(-)	Pagos de mayor tamaño indican mayor capacidad y compromiso de pago
R4_savings_rate	$\frac{\text{Amount invested monthly}}{\text{Monthly Inhaled salary} + \epsilon}$	(-)	Mayor tasa de ahorro implica disciplina financiera y capacidad para afrontar obligaciones
R5_interest_stress	Outstanding Debt / Annual Income	(+)	Presión financiera combinada por costo de deuda y nivel de endeudamiento. Mayor estrés implica mayor riesgo
Spending_level	Codificación binaria: Low=0, High=1	(-)	Empíricamente, niveles de gasto más altos se asocian con mayor capacidad económica

Los signos de todos los coeficientes se fijaron antes de la optimización, garantizando que el modelo sea económicamente coherente independientemente de los valores específicos de los pesos encontrados por cada método de búsqueda.

4.3 Ingeniería de Características y Construcción de Ratios

Las siete variables del modelo no provienen directamente del dataset limpio, sino que son transformaciones construidas a partir de las variables originales. Esta etapa de ingeniería de características responde a un problema fundamental de los modelos lineales: cuando las variables de entrada están expresadas en unidades absolutas y de distinta magnitud, el score queda dominado por las variables de mayor escala numérica, independientemente de su relevancia económica real.

La solución adoptada, consistente con el enfoque de Altman, consiste en construir ratios financieros que normalizan cada variable por una referencia económicamente relevante. De esta forma, el ingreso anual, la deuda pendiente y el saldo mensual no compiten en escala dentro del score, sino que contribuyen a través de proporciones comparables entre clientes.

En total se construyeron diez ratios financieros candidatos a partir de las variables limpias del dataset:

R1	Outstanding Debt / Annual income	Debt to income
R2	Total EMI per month / Monthly Inhlald salary	EMI burden
R3	Monthly balance / Total EMI per motnh	Balance coverage
R4	Amount invested monthly / Monthly Inhlald salart	Savings Rate
R5	Interest rate * R1	Interest stress
R6	Changed credit limit / Annual Income	Limit shock relative
R7	Num_credit_inquiries / Credit History Months	Inquiry intensity
R8	Num of delayed payments / Num of loans	Delays per Loan
R9	Outstanding debt / Num credit card	Debt per card
R10	Delay from due date / Credit history months	Delay intensity adjusted

Un caso especial es R3, que presenta alta asimetría positiva debido a que su denominador puede acercarse a cero, generando valores extremadamente grandes que inflan la varianza y desestabilizan el modelo lineal. Para corregir este comportamiento sin recurrir a normalización estadística, se aplicó una transformación logarítmica:

$$R3_{\log} = \log(1 + R3)$$

Esta transformación comprime la cola derecha de la distribución, preserva el orden de los valores con menor asimetría y rangos comparables con las demás variables del modelo.


4.4 Proceso de Selección de Variables

De los diez ratios construidos más las variables originales disponibles, se realizó un proceso de selección para determinar el subconjunto final de siete variables que entran al modelo. Este proceso siguió tres criterios simultáneos.

El primero fue la **significancia estadística**, evaluada mediante una regresión logística preliminar usado exclusivamente como herramienta de selección. Se conservaron únicamente variables con $p\text{-value} < 0.05$. Este criterio permitió descartar variables cuya relación con el default no es estadísticamente distinguible del ruido

El segundo criterio fue la **baja correlación entre variables**. Se eliminaron pares con correlación superior a 0.7 en valor absoluto, conservando en cada par la variable con mayor AUC individual. Este paso previene la multicolinealidad, que en modelos lineales puede generar coeficientes inestables y difíciles de interpretar.

El tercer criterio fue la verificación del **Factor de Inflación de la Varianza (VIF)**. Todas las variables del modelo final presentaron VIF entre 1.03 y 1.75, muy por debajo del umbral crítico de 5, confirmando la ausencia de multicolinealidad relevante.



La matriz de correlación confirma que las siete variables seleccionadas son independientes entre sí. Ningún par supera una correlación de $|0.60|$ en valor absoluto, y la gran mayoría se ubica por debajo de $|0.30|$, lo que descarta multicolinealidad. Cada variable captura una dimensión distinta del perfil de riesgo del cliente — liquidez, edad, diversificación crediticia, comportamiento de pago, ahorro, estrés financiero y nivel de gasto — sin redundancia informacional entre ellas. Esto es consistente con los valores de VIF calculados para cada variable, todos entre 1.03 y 1.75.

4.5 Separación de Datos y Protocolo de Evaluación

Para garantizar una evaluación imparcial del modelo y evitar cualquier forma de data leakage, el dataset se dividió en tres subconjuntos mutuamente excluyentes mediante muestreo estratificado por la variable objetivo:

Conjunto	Proporción	Uso
Subtrain	60%	Optimización de pesos y calibración del umbral
Validación	20%	Selección del modelo final entre métodos
Test	20%	Evaluación final, usada una única vez

La estratificación garantiza que la tasa de default de aproximadamente 29% se preserve en los tres conjuntos. El conjunto de test permaneció completamente bloqueado durante todo el proceso de optimización y selección, siendo consultado únicamente para reportar las métricas finales. Esta separación es crítica porque el umbral de decisión T se calibra sobre el subtrain: si el test participara en esta etapa, las métricas reportadas sobreestimarían el desempeño real fuera de muestra.

4.6 Optimización de Pesos

Los pesos del modelo se determinaron mediante tres métodos de búsqueda numérica aplicados de forma independiente sobre el conjunto de subtrain. En los tres casos, la función objetivo que se maximiza es la exactitud de clasificación, y los pesos están acotados por variable mediante límites derivados del rango intercuartílico del subtrain:

$$u_j^{max} = \min \left(\frac{C}{P_{95}^{(j)} - P_5^{(j)}}, 10 \right)$$

Donde $C = 2.0$ es el impacto máximo permitido por variable en su rango típico. Este mecanismo de acotamiento evita que ninguna variable domine el score por efecto de escala residual, sin requerir estandarización de los datos.

La **Simulación Monte Carlo** generó 50,000 combinaciones aleatorias de pesos dentro de los límites establecidos. Para cada combinación se calculó el umbral proporcional sobre el subtrain, se evaluó la exactitud en validación y se conservó la combinación con mejor desempeño. Este método cubre ampliamente el espacio de búsqueda con la ventaja de ser completamente reproducible dado un estado inicial fijo.

La **Evolución Diferencial** utilizó una población de 20 individuos evolucionando durante 300 generaciones con estrategia **best1bin**. A diferencia de Monte Carlo, este método guía la búsqueda de forma adaptativa hacia regiones más prometedoras del espacio de parámetros, siendo más eficiente cuando la función objetivo presenta estructura aprovechable.

El **Recocido Dual** ejecutó 7,000 iteraciones alternando entre exploración global y refinamiento local. Este método es particularmente robusto ante funciones objetivo con múltiples óptimos locales, ya que su mecanismo de temperatura le permite escapar de soluciones subóptimas durante la fase de exploración.

4.7 Selección del Modelo Final y Regla de Decisión

Los tres métodos de optimización produjeron modelos distintos que fueron evaluados simultáneamente sobre los conjuntos de subtrain, validación y test. La selección del modelo final se realizó exclusivamente con base en el desempeño sobre el conjunto de validación, con la exactitud en subtrain como criterio de desempate. La siguiente tabla presenta la comparación completa:

Modelo	Accuracy SUB	Accuracy VAL	Accuracy TEST
Monte Carlo	0.7810	0.7835	0.7768
Evolución diferencial	0.7826	0.7832	0.7768
Recocido Dual	0.7824	0.7837	0.7775

El método de **Recocido Dual** fue seleccionado como modelo final al presentar el mejor desempeño. La fórmula resultante del score es:

$$Z = -0.096331 \times R3_log - 0.002342 \times Age - 0.453616 \times Credit_Mix_final - 0.000910 \times Payment_Size_final - 1.040142 \times R4_Savings_Rate + 0.167495 \times R5_Interest_Stress - 0.162791 \times Spending_Level_final$$

Regla de decision:

Si $Z \geq -0.498846 \rightarrow \text{DEFAULT (Poor = 1)}$

Si $Z < -0.498846 \rightarrow \text{NO DEFAULT (0)}$

V. RESULTADOS

5.1 Significancia de las variables

Como paso previo a la optimización de pesos, se estimó una regresión logística sobre las siete variables seleccionadas con el único propósito de verificar su significancia estadística individual.

Los resultados se presentan en la siguiente tabla

```

Optimization terminated successfully.
Current function value: 0.531289
Iterations 6

Logit Regression Results
=====
Dep. Variable:      Y_default    No. Observations:    100000
Model:              Logit        Df Residuals:        99992
Method:              MLE         Df Model:            7
Date:               Thu, 05 Mar 2026    Pseudo R-squ.:      0.1177
Time:               16:27:06          Log-Likelihood:      -53129.
converged:           True           LL-Null:             -60213.
Covariance Type:     nonrobust       LLR p-value:         0.000
=====
              coef    std err          z      P>|z|      [0.025    0.975]
-----
const          0.4129    0.039     10.487    0.000     0.336    0.490
R3_log         -0.0327    0.002    -18.658    0.000    -0.036   -0.029
Age            -0.0092    0.001    -11.330    0.000    -0.011   -0.008
Credit_Mix_final -0.8035    0.013   -61.387    0.000    -0.829   -0.778
Payment_Size_final -0.0944    0.010    -9.120    0.000    -0.115   -0.074
R4_Savings_Rate -2.3367    0.299    -7.825    0.000    -2.922   -1.751
R5_Interest_Stress 0.1210    0.004    30.665    0.000     0.113    0.129
Spending_Level_final -0.2478    0.019   -12.956    0.000    -0.285   -0.210
=====

```

Las siete variables presentan $p\text{-value} = 0$, confirmando significancia estadística al nivel del 1% en todos los casos. Ninguna variable requirió exclusión por falta de significancia en esta etapa final.

Varios aspectos destacan del análisis. El estadístico z más alto en valor absoluto corresponde a **Credit mix final** con $z = -61.39$, lo que indica que la estructura del crédito del cliente es la variable con mayor poder discriminante individual dentro del modelo.

Los signos de todos los coeficientes son consistentes con los asignados por teoría económica antes de la optimización: las variables que reducen el riesgo presentan coeficientes negativos y la única variable que incrementa el riesgo, **R5_Interest_Stress**, presenta coeficiente positivo. Esta consistencia entre la dirección teórica esperada y los coeficientes empíricamente estimados constituye una validación adicional de la coherencia económica del modelo.

5.2 Contribución de Variables al Score

Además de la significancia estadística, se calculó la contribución promedio de cada variable al score mediante la métrica de contribución absoluta media, definida como:

Esta métrica cuantifica cuánto aporta en promedio cada variable al valor del score, considerando tanto el peso asignado como la magnitud típica de la variable en la muestra. Los resultados sobre el conjunto de subtrain son los siguientes:

Ranking	Variable	Contribución Media Absoluta	Contribución Relativa
1	Credit Mix final	0.4831	38.8%
2	R3 log	0.3530	28.3%
3	R5 Interest stress	0.2079	16.7%
4	Age	0.0803	6.4%
5	Spending level	0.0692	5.6%
6	R4 Savings rate	0.0548	4.4%
7	Payment size	0.0007	0.1%

La contribución relativa se calculó como la proporción de cada variable sobre la suma total de contribuciones absolutas medias.

Los resultados revelan una jerarquía clara entre las variables del modelo. **Credit_Mix_final** es la variable dominante, explicando casi el 39% de la magnitud total del score. Este resultado es consistente con la literatura de credit scoring, donde la estructura y diversificación del portafolio crediticio del cliente constituye uno de los factores más informativos del perfil de riesgo individual, comparable al rol que juega en sistemas como FICO.

R3_log, que captura la capacidad del cliente para cubrir sus obligaciones de pago con el saldo mensual disponible, ocupa el segundo lugar con una contribución del 28.3%. Su presencia en los primeros lugares confirma que la liquidez relativa es un determinante central del riesgo de incumplimiento en el crédito al consumo.

R5_Interest_Stress, la única variable con signo positivo en el modelo, aporta el 16.7% de la contribución total. Esta ratio combina la tasa de interés con el nivel de endeudamiento relativo al ingreso, capturando la presión financiera combinada que enfrenta el cliente por el costo de su deuda.

En conjunto, estas tres variables concentran el 83.8% de la contribución total al score, mientras que las cuatro variables restantes aportan el 16.2% restante.

5.3 Resultados del mejor modelo

El modelo seleccionado corresponde al obtenido mediante Recocido Dual, elegido por presentar el mejor desempeño en el conjunto de validación. Su evaluación final sobre el conjunto de prueba, consultado una única vez al término del proceso de optimización, arrojó los siguientes resultados.

Métricas Globales

Métrica	Valor
Accuracy	0.7775
ROC-AUC	0.7478
Tasa de default predicha	0.2907
Tasa de default real	0.2900
Diferencia de calibración	0.0007

El ROC-AUC de 0.7478 indica una capacidad discriminante moderada-alta, significativamente superior al valor de 0.50 que correspondería a clasificación aleatoria. La diferencia entre la tasa de default predicha (29.07%) y la real (29.00%) es de apenas 0.07 puntos porcentuales, confirmando que el modelo está correctamente calibrado a nivel agregado gracias al mecanismo de umbral proporcional.

Reporte de clasificación por clase

Clase	Precisión	Recall	F1-score	Soporte
No default	0.8437	0.8429	0.8433	14,200
Default	0.6162	0.6176	0.6169	5,800
Macro avg	0.7299	0.7302	0.7301	20,000
Weighted avg	0.7777	0.7775	0.7776	20,000

El modelo presenta un desempeño asimétrico entre clases, característico de problemas con desbalance moderado. Para los clientes sin default, la precisión alcanza 0.8437 y el recall 0.8429, lo que significa que el 84.3% de los clientes solventes son correctamente identificados. Para los clientes en default, la precisión es de 0.6162 y el recall de 0.6176, detectando correctamente el 61.8% de los incumplimientos reales.

Matriz de confusión

	Pred: No default	Pred: Default
Real: No Default	11,969	2,231
Real: Default	2,218	3,582

Los errores se distribuyen en dos tipos. Los **falsos negativos** son 2,218 clientes en default que el modelo clasifica incorrectamente como solventes; estos representan los casos más costosos desde la perspectiva de la institución financiera, ya que corresponden a créditos que serían otorgados a clientes que eventualmente incumplirán. Los **falsos**

positivos son 2,231 clientes solventes clasificados incorrectamente como default, lo que representaría rechazos injustificados de crédito.

Tasas de Error por Tipo

Métrica	Valor	Interpretación
FNR (False Negative Rate)	0.3824	38.2% de los defaults reales no son detectados
FPR (False Positive Rate)	0.1571	15.7% de los clientes solventes son rechazados incorrectamente

La tasa de falsos negativos del 38.2% refleja la dificultad inherente de detectar todos los incumplimientos en un modelo lineal con variables limitadas. Sin embargo, la tasa de falsos positivos del 15.7% es relativamente contenida, lo que significa que el modelo no penaliza excesivamente a clientes solventes. Este balance entre FNR y FPR puede ajustarse modificando el umbral de decisión T según las prioridades operativas de la institución: reducir el umbral aumenta la sensibilidad hacia defaults a costa de más falsos positivos, y viceversa.

5.4 Distribución del Score por Clase




Figura 1. Distribución del Score Z — Subtrain, Modelo 3 Dual Annealing (Accuracy SUB: 0.7824 | VAL: 0.7837 | TEST: 0.7775)

La Figura 1 presenta la distribución de densidad del score Z sobre el conjunto de subtrain, separada por clase (Default y No Default), junto con el umbral de decisión $T = -0.4988$.

El gráfico permite observar varios aspectos relevantes del comportamiento del modelo.

Separación entre clases. Las distribuciones de Default y No Default presentan medias claramente diferenciadas. Los clientes sin default se concentran en la región izquierda del score (valores más negativos), mientras que los clientes en default se desplazan hacia la región derecha (valores menos negativos o positivos). Esto confirma que el score ordena correctamente el riesgo crediticio en la dirección esperada: score alto implica mayor riesgo.

Solapamiento parcial. Ambas distribuciones se superponen en la región central, aproximadamente entre $Z = -1.5$ y $Z = 0.5$. Este solapamiento es inherente al problema y refleja que existe una porción de clientes cuyo perfil financiero no permite una clasificación perfectamente limpia mediante un único umbral lineal. Es precisamente este solapamiento el que determina los errores de clasificación reportados en la sección anterior.

Posición del umbral. La línea discontinua negra en $T = -0.4988$ divide el espacio del score en dos regiones. Todo cliente con $Z > -0.4988$ es clasificado como Default (región roja) y todo cliente con $Z < -0.4988$ como No Default (región azul). La posición del umbral fue determinada por el cuantil $1-p = 1-0.28998$ de la distribución del score en subtrain, garantizando que aproximadamente el 29% de los clientes con scores más altos sean clasificados como default, en línea con la tasa real observada.

6.5 Tasa de Default por Cuantil del Score




Figura 2. Default Rate by Score Quantile — Subtrain, Modelo 3 Dual Annealing

La Figura 2 presenta la tasa de default observada para cada decil del score, ordenados de menor a mayor riesgo (bins 0 al 9), calculada sobre el conjunto de subtrain.

Este gráfico evalúa una propiedad fundamental que debe cumplir cualquier modelo de scoring crediticio: la **monotonidad del riesgo**. Un score bien construido debe asignar tasas de default crecientes conforme aumenta el valor del score, de modo que los bins superiores concentren sistemáticamente más incumplimientos que los inferiores.

Comportamiento general. Los resultados muestran una tendencia predominantemente creciente a lo largo de los deciles. Los bins del 0 al 4 presentan tasas de default bajas y relativamente estables, oscilando entre 0.08 y 0.16, lo que corresponde a la población de menor riesgo del portafolio. A partir del bin 6 se observa un salto pronunciado, con la tasa escalando desde 0.27 hasta alcanzar su máximo de 0.69 en el bin 7, para luego estabilizarse en torno a 0.55–0.63 en los bins 8 y 9.

Concentración del riesgo. El salto más significativo ocurre entre el bin 6 (0.27) y el bin 7 (0.69), una diferencia de 42 puntos porcentuales. Esto indica que el score logra identificar con precisión una región de alto riesgo donde la probabilidad de default es casi 2.4 veces la tasa base del dataset (29%). Los tres deciles superiores (7, 8 y 9) concentran tasas de default entre 55% y 69%, muy por encima del promedio, lo que confirma el poder discriminante del score en la cola de mayor riesgo.

Ligera no monotonidad. Se observa una pequeña irregularidad entre los bins 3 y 4, donde la tasa desciende de 0.15 a 0.10 antes de volver a subir. Este comportamiento es esperado en modelos lineales aplicados a datos reales con ruido, y no compromete la utilidad operativa del score dado que la tendencia global es claramente creciente. Esta no monotonidad local es típica cuando se trabaja con deciles sobre muestras finitas y no implica un defecto estructural del modelo.

Implicación operativa. La estructura del gráfico sugiere una segmentación natural del portafolio en tres zonas: una zona de bajo riesgo correspondiente a los bins 0–5 con tasas inferiores al 20%, una zona de transición en el bin 6 con tasa del 27%, y una zona de alto riesgo en los bins 7–9 con tasas superiores al 55%. Esta segmentación es la base para la construcción de los niveles de riesgo Good, Standard y High Risk que se presentan en la siguiente sección.

6.6 Distribución del Score por Segmento de Riesgo




Figura 3. Distribución del Score por Segmento de Riesgo — Test, Modelo 3 Dual Annealing

La Figura 3 presenta la distribución de densidad del score Z sobre el conjunto de prueba, separada por los tres segmentos de riesgo definidos a partir de los cuantiles del score: **Good** (bins 0–4), **Standard** (bins 5–6) y **High Risk** (bins 7–9).

La gráfica revela una separación notable entre los tres segmentos, con características distintivas para cada uno.

Segmento Good (verde). Concentrado en la región de scores más bajos, aproximadamente entre $Z = -3.5$ y $Z = -0.8$. Su distribución es bimodal, con dos picos alrededor de $Z = -2.8$ y $Z = -1.3$, y una cola que se extiende hacia la derecha antes de cortarse abruptamente en el límite del segmento. Este segmento agrupa a los clientes con menor probabilidad de incumplimiento, cuyo score refleja perfiles financieros sólidos con alta cobertura de liquidez, buena mezcla crediticia y bajo estrés por intereses.

Segmento Standard (naranja). Presenta una distribución extremadamente concentrada y estrecha alrededor de $Z \approx -0.75$, con una densidad máxima superior a 6.0, la más alta de los tres segmentos. Esta concentración indica que los clientes clasificados como Standard tienen scores muy similares entre sí, ubicándose en la zona de transición inmediatamente a la izquierda del umbral de decisión $T = -0.4988$. Son clientes con un perfil de riesgo intermedio cuya clasificación podría variar ante pequeños cambios en sus variables financieras.

Segmento High Risk (rojo oscuro). Distribuido principalmente en la región de scores positivos y moderadamente negativos, entre $Z \approx -0.5$ y $Z = 3.5$, con un pico de densidad alrededor de $Z = 0.2$. Su distribución es unimodal y con cola derecha pronunciada, reflejando que este segmento captura a los clientes con mayor estrés financiero, menor capacidad de cobertura y estructuras de crédito más débiles.

Separación entre segmentos. Los tres segmentos ocupan regiones del eje del score prácticamente no superpuestas, lo que confirma que la segmentación por cuantiles produce grupos internamente homogéneos y externamente diferenciados. Esta propiedad es esencial para la utilidad operativa del modelo: permite que las decisiones crediticias —aprobación automática, revisión adicional o rechazo— se asignen a grupos con perfiles de riesgo genuinamente distintos y no arbitrariamente definidos.

5.7 Distribución del Score por Segmento — Boxplot




Figura 4. Distribución del Score por Segmento de Riesgo (Boxplot) — Test, Modelo 3 Dual Annealing

La Figura 4 presenta los diagramas de caja del score ZZZ para cada segmento de riesgo sobre el conjunto de prueba.

Los tres segmentos presentan medianas claramente diferenciadas y no superpuestas. **Good** se concentra alrededor de $Z \approx -1.2$ con una dispersión moderada y algunos valores atípicos en la cola inferior hasta $Z = -3.0$. **Standard** es el segmento más compacto, con mediana en $Z \approx -0.7$ y rangos intercuartílicos muy estrechos, confirmando la homogeneidad observada en la figura anterior. **High Risk** presenta la mayor dispersión, con mediana cercana a $Z \approx 0.1$ y una cola superior extensa con numerosos valores atípicos que alcanzan $Z = 3.0$, reflejando la heterogeneidad interna del grupo de mayor riesgo.

La ausencia de solapamiento entre las cajas de los tres segmentos confirma que la segmentación produce grupos estadísticamente distinguibles, validando su utilidad como herramienta operativa de clasificación crediticia.

5.8 Curva KS, Cumulative gains y Lift por decil

¿Qué es la estadística KS?

La estadística de Kolmogorov-Smirnov (KS) mide la máxima separación entre las funciones de distribución acumulada del score para los clientes en default y los clientes solventes. En términos simples, responde a la pregunta: ¿en qué punto del score el modelo logra separar mejor a ambas poblaciones? Un KS de 0 indica que el modelo no distingue entre clases en absoluto, equivalente a clasificación aleatoria, mientras que un KS de 1 representaría separación perfecta. En la industria financiera, valores de KS superiores a 0.40 se consideran indicativos de un modelo con buen poder discriminante.




Figura 5. Curva KS — Test, Modelo 3 Dual Annealing (KS = 0.489)

La curva naranja representa la CDF acumulada de los clientes **No Default** y la curva azul la de los clientes en **Default**. Un modelo con poder discriminante desplaza la CDF de No Default hacia la izquierda —scores bajos— y la CDF de Default hacia la derecha —scores altos—, generando una brecha visible entre ambas curvas.

El modelo alcanza una **estadística KS = 0.489** en el punto $Z = -0.629$, indicando que en ese valor del score la diferencia entre ambas distribuciones acumuladas es máxima. Esto significa que, hasta ese punto del score, el 83% de los clientes No Default ya han sido clasificados, mientras que solo el 33% de los clientes en Default han sido capturados, generando una separación de 49 puntos porcentuales entre ambas poblaciones. Un KS de 0.489 se sitúa en el rango de **buen poder discriminante** según los estándares de la industria crediticia.

Curva de Ganancias Acumuladas




Figura 6. Cumulative Gains — Test, Modelo 3 Dual Annealing

La curva azul del modelo se separa notablemente de la línea diagonal naranja que representa la clasificación aleatoria en todos los puntos. Los resultados más relevantes son que revisando el 20% más riesgoso del portafolio se captura el 40% de los defaults, revisando el 30% se captura el 63.5%, y revisando el 50% se alcanza el 78% de todos los incumplimientos reales.

La distancia entre la curva del modelo y la línea aleatoria representa la ganancia operativa que aporta el score: en lugar de revisar aleatoriamente a los clientes, el modelo permite concentrar los esfuerzos de gestión de riesgo en la fracción más peligrosa del portafolio, capturando una proporción desproporcionadamente alta de defaults con una fracción relativamente pequeña de la cartera total.

Lift por Decil de Riesgo




Figura 7. Lift por Decil de Riesgo — Test, Modelo 3 Dual Annealing

La Figura 7 presenta el lift por decil sobre el conjunto de prueba, donde el decil 0 corresponde a los clientes con score más alto —mayor riesgo— y el decil 9 a los de menor riesgo.

La línea discontinua horizontal en Lift=1.0 representa el desempeño de un clasificador aleatorio. Las barras por encima de esta línea indican deciles donde el modelo supera la selección aleatoria, mientras que las barras por debajo corresponden a deciles donde la concentración de defaults es inferior a la tasa base del 29%.

Los tres primeros deciles (0, 1 y 2) presentan lifts de 1.87, 2.18 y 2.30 respectivamente, todos muy por encima del umbral aleatorio. El decil 3 se sitúa prácticamente sobre la línea con lift de 0.97, marcando la frontera natural entre la zona de alto riesgo y el resto del portafolio. A partir del decil 4 los lifts caen consistentemente por debajo de 1.0, confirmando que estos segmentos contienen una proporción de defaults inferior a la tasa base, es decir, son poblaciones predominantemente solventes.

La estructura del gráfico refuerza la recomendación operativa derivada del modelo: focalizar las acciones de gestión de riesgo —revisión manual, garantías adicionales o restricción de crédito— en los tres primeros deciles, que concentran el mayor poder predictivo del score con lifts superiores a 1.87.

VI. JUSTIFICACIÓN

Esta sección presenta la justificación económica de los coeficientes del modelo. Para cada variable se argumenta el signo asignado, la magnitud relativa del peso y su respaldo en la literatura de riesgo crediticio y en metodologías de agencias como FICO, Moody's y S&P Global.

6.1 R3_log — Cobertura de Balance (log)

Definición

$$R3 = \text{Monthly_Balance} / (\text{Total_EMI_per_month} + \epsilon) \rightarrow R3_log = \ln(1 + R3)$$

Signo: Negativo (–) | Peso: –0.096331 (5° mayor magnitud)

Este ratio captura la **capacidad de liquidez disponible relativa a las obligaciones de pago mensual**. Un valor alto de R3 indica que el cliente mantiene saldo disponible muy superior a sus compromisos de deuda, lo que reduce significativamente la probabilidad de incumplimiento. Este concepto es análogo al ratio **Current Ratio** utilizado en el Altman Z-Score para empresas ($X_1 = \text{Capital de Trabajo} / \text{Activos Totales}$), donde valores mayores reducen el score de quiebra.

La transformación logarítmica $\ln(1 + R3)$ se justifica porque la distribución de R3 presenta alta asimetría positiva: cuando el denominador (EMI) se aproxima a cero, el ratio puede tomar valores extremadamente grandes sin que ello implique capacidad financiera infinitamente mayor. El logaritmo comprime estas colas preservando la monotonía ($\partial R3_log / \partial R3 > 0$), garantizando que la relación con el riesgo conserve el signo correcto. Esta es una práctica estándar en econometría financiera para variables con distribuciones sesgadas (Greene, 2018; Cameron & Trivedi, 2005).

Evidencia empírica

Pagos de cuota como porcentaje del ingreso (Payment-to-Income Ratio, PTI) son monitoreados de cerca por prestamistas. Estudios del Consumer Financial Protection Bureau (CFPB, 2022) demuestran que clientes con mayor liquidez disponible post-pago presentan tasas de default hasta un 40% menores que clientes ajustados al límite de su capacidad de pago. Asimismo, el Banco de Pagos Internacionales (BIS, 2021) documenta que la cobertura de liquidez de corto plazo es el predictor más robusto de estrés financiero individual.

"Liquidity coverage ratios are among the strongest predictors of household financial distress across income levels" (BIS Working Paper No. 942, 2021).

6.2 Age — Edad del Cliente

Definición

Variable demográfica que captura la edad en años del solicitante de crédito.

Signo: Negativo (–) | Peso: –0.002342 (6° mayor magnitud)

La relación entre edad y riesgo crediticio está ampliamente documentada. Clientes de mayor edad exhiben sistemáticamente mayor estabilidad laboral, historial crediticio más extenso y mayor disciplina financiera acumulada, lo que reduce la

probabilidad de incumplimiento. La magnitud relativamente baja del peso (-0.0023) no contradice la relevancia económica de la variable: refleja que la edad opera en una escala absoluta (años) con rango amplio, por lo que incluso un peso pequeño genera contribuciones acumuladas significativas en el score. Este resultado es robusto a través de múltiples estudios y contextos geográficos.

FICO Score explícitamente incluye la edad de las cuentas crediticias como componente (15% del score total bajo el concepto *"Length of Credit History"*), reconociendo que el tiempo de exposición al sistema financiero reduce el riesgo percibido. Adicionalmente, investigación del Federal Reserve Bank of New York (Haughwout et al., 2019) muestra que la probabilidad de transición a delinquency disminuye monótonamente con la edad después de los 30 años.

Evidencia empírica

Gross & Souleles (2002) encuentran en su análisis de cuentas de tarjeta de crédito en EE.UU. que la edad es un predictor negativo y significativo de default, con elasticidades que van de -0.3 a -0.7 dependiendo del rango de edad.

"Age is negatively and significantly associated with default probability across all credit score deciles" (Gross & Souleles, 2002, Journal of Finance, Vol. 57, No. 1).

6.3 Credit_Mix_final — Diversificación del Crédito

Definición

Variable ordinal que clasifica la calidad de la mezcla crediticia del cliente. Refleja la diversidad y salud del portafolio de créditos activos (tarjetas, préstamos, hipotecas, etc.).

Signo: Negativo (-) | Peso: -0.453616 (2° mayor magnitud)

El Credit Mix es uno de los cinco componentes del score FICO, representando el 10% del score total (FICO, 2022). Una mezcla crediticia saludable indica que el cliente ha gestionado exitosamente diferentes tipos de obligaciones financieras, lo que reduce su probabilidad de incumplimiento futuro. El modelo asigna a esta variable el segundo mayor peso en magnitud (-0.4536), superando a variables como el estrés por intereses y el nivel de gasto.

Esta variable captura información que va más allá de la cantidad de crédito: refleja la capacidad de gestión financiera multidimensional del cliente. Moody's (2021) y S&P Global (2020) incluyen la diversificación de obligaciones como factor cualitativo en sus metodologías de calificación de crédito al consumo, argumentando que clientes con mezclas crediticias más complejas han demostrado mayor resiliencia ante choques financieros.

Evidencia empírica

Avery et al. (2003), en su análisis para la Federal Reserve, documentan que la tipología de crédito activo es uno de los predictores más estables de default en el largo plazo. Bhutta & Keys (2016) corroboran que la presencia de créditos hipotecarios (componente de una mezcla crediticia diversificada) actúa como ancla de disciplina financiera, reduciendo defaults en créditos no garantizados.

"Credit mix is one of the most stable long-run predictors of default behavior, reflecting financial management capacity rather than point-in-time leverage" (Avery, Calem & Canner, 2003, Federal Reserve Bulletin).

6.4 R4_Savings_Rate — Tasa de Ahorro

Definición

$$R4 = \text{Amount_invested_monthly} / (\text{Monthly_Inhand_Salary} + \epsilon)$$

Signo: Negativo (-) | Peso: -1.040142 (1° — mayor magnitud del modelo)

La tasa de ahorro recibe el mayor peso en magnitud del modelo (-1.0401), más del doble que la segunda variable. Este resultado no es arbitrario: refleja que la tasa de ahorro es un indicador directo de la disciplina financiera y la capacidad de absorber choques adversos de ingresos. Un cliente que ahorra consistentemente tiene colchones financieros que le permiten cumplir con sus obligaciones crediticias incluso ante eventos inesperados (pérdida de empleo, gastos médicos, etc.). Además, a diferencia de variables de comportamiento pasado, la tasa de ahorro captura el *comportamiento financiero actual*, siendo un predictor forward-looking del riesgo.

Este concepto es análogo al ratio $X_2 = \text{Utilidades Retenidas} / \text{Activos Totales}$ del Z-Score de Altman, donde empresas que generan y retienen utilidades tienen menor probabilidad de quiebra. En el contexto de finanzas personales, el ahorro cumple el mismo rol que las utilidades retenidas en una empresa: capital disponible para enfrentar adversidades.

El Fondo Monetario Internacional (IMF Working Paper WP/19/182) documenta que hogares con tasas de ahorro positivas tienen probabilidades de default significativamente menores, con efectos especialmente pronunciados en países emergentes donde las redes de seguridad social son más débiles.

Evidencia empírica

Lusardi & Mitchell (2014) demuestran que la *financial literacy*, de la cual el ahorro es una expresión directa, reduce la probabilidad de acumular deudas problemáticas en un 12-18%. Campbell (2006) encuentra que hogares con mayor tasa de ahorro son significativamente menos propensos a experimentar distress financiero, resultado consistente en múltiples países de la OCDE.

"Savings rates are inversely correlated with household financial distress, with effects robust to income controls and across demographic groups" (Lusardi & Mitchell, 2014, Journal of Economic Literature, Vol. 52, No. 1).

6.5 R5_Interest_Stress — Estrés por Tasa de Interés

Definición

$$R5 = \text{Interest_Rate} \times R1_DTI = \text{Interest_Rate} \times (\text{Outstanding_Debt} / \text{Annual_Income})$$

Signo: Positivo (+) | Peso: +0.167495 (3º mayor magnitud — única variable de riesgo positivo)

R5 es el único regresor con signo positivo en el modelo, reflejando que representa **presión financiera directa**. Esta variable combina dos dimensiones de riesgo simultáneamente: el nivel de endeudamiento relativo al ingreso (DTI) y el costo de ese endeudamiento (tasa de interés). El producto de ambos captura la **carga de intereses como proporción del ingreso**, un indicador de estrés financiero estructural.

Este diseño está inspirado en el concepto de **Debt Service Coverage Ratio (DSCR)** utilizado por instituciones financieras internacionales. El IMF Working Paper WP/19/182 documenta explícitamente que la relación entre DTI y probabilidad de default es no lineal y que el costo del crédito amplifica el efecto del endeudamiento: un cliente con alto DTI y tasas de interés elevadas enfrenta una presión financiera desproporcionadamente mayor que la suma de ambos factores por separado.

Moody's Analytics (2023) en sus modelos de calificación de portafolios de crédito al consumo incluye el *interest burden* (carga de intereses / ingreso) como una de las tres variables clave en la estimación de *probability of default* (PD) bajo marcos de Basilea III.

Evidencia empírica

Dynan et al. (2012) encuentran en datos del Panel Study of Income Dynamics (PSID) que hogares con altos pagos de intereses relativos al ingreso tienen probabilidades de default 3.2x mayores que hogares con baja carga de intereses, incluso controlando por nivel absoluto de deuda. El efecto es aún más pronunciado en entornos de tasas altas o volátiles, lo que justifica incluir la tasa de interés como multiplicador del endeudamiento.

"Interest burden — the ratio of interest payments to household income — is one of the strongest predictors of delinquency, outperforming simple leverage ratios" (Dynan, Elmendorf & Sichel, 2012, Brookings Papers on Economic Activity).

6.6 Spending_Level_final — Nivel de Gasto

Definición

Variable ordinal que clasifica el nivel de gasto del cliente. Captura la intensidad del consumo en relación a su perfil financiero general.

Signo: Negativo (–) | Peso: –0.162791 (4º mayor magnitud)

A primera vista, podría parecer contraintuitivo que un mayor nivel de gasto reduzca el riesgo de default. Sin embargo, el análisis económico revela que en la población de solicitantes de crédito, el nivel de gasto observable está **positivamente correlacionado con el nivel de ingreso**. Clientes con mayor capacidad de gasto demuestran implícitamente mayor solvencia económica, ya que pueden mantener niveles de consumo más altos mientras cumplen con sus obligaciones crediticias.

Este resultado es consistente con la evidencia de la literatura de consumo: Bertaut & Haliassos (2006) documentan que los patrones de gasto con tarjeta de crédito son señales positivas de solvencia cuando se controla por nivel de ingreso. El mecanismo económico es que clientes de mayor ingreso tanto gastan más *como* mantienen mayor capacidad de pago, haciendo que el nivel de gasto sea un proxy positivo del perfil crediticio en la muestra de clientes con acceso al sistema financiero formal.

Esta relación también es capturada por el componente de **Credit Utilization** en los modelos FICO: utilización moderada-alta (no extrema) combinada con pagos consistentes es señal de un cliente activo y solvente. El *spending level* en este modelo captura esa dimensión de actividad financiera.

Evidencia empírica

Agarwal et al. (2018) en su análisis de Big Data de consumo con tarjetas de crédito encuentran que el *spending level* tiene una relación en forma de U invertida con el default: niveles muy bajos (clientes financieramente marginados) y niveles extremadamente altos (sobre-consumo) presentan mayor riesgo, mientras que niveles moderados-altos — consistentes con mayor ingreso y disciplina — presentan el menor riesgo, justificando el signo negativo en la población general de clientes con acceso a crédito formal.

"Spending patterns are informative about creditworthiness: moderate-to-high spending by credit users is associated with lower default rates, reflecting income capacity" (Agarwal et al., 2018, Review of Financial Studies, Vol. 31, No. 11).

6.7 Payment_Size_final — Tamaño Relativo del Pago

Definición

Variable ordinal que captura el tamaño del pago realizado en relación al saldo adeudado. Distingue entre clientes que pagan el mínimo, un monto intermedio o el saldo completo.

Signo: Negativo (–) | Peso: –0.000910 (7° — menor magnitud)

El comportamiento de pago es ampliamente reconocido como uno de los determinantes más relevantes del riesgo crediticio. El tamaño del pago captura la **capacidad financiera disponible en el margen**: un cliente que paga más del mínimo demuestra liquidez disponible y disciplina financiera. Sin embargo, en un modelo multivariado esta información está parcialmente contenida en variables que miden el mismo constructo de forma más estructural y continua: R4_Savings_Rate captura el comportamiento de ahorro habitual, y R3_log refleja la liquidez disponible relativa a las obligaciones de pago. Quien mantiene una tasa de ahorro positiva y cobertura de balance adecuada es, por construcción económica, quien tiene capacidad de realizar pagos de mayor tamaño. La contribución marginal de Payment_Size, dado el conjunto de variables del modelo, es por tanto más acotada que su relevancia aislada sugeriría.

Este fenómeno está respaldado por la literatura de credit scoring: Siddiqi (2012) documenta que en modelos lineales con variables financieramente relacionadas, el peso de cada variable refleja su aportación *incremental* una vez que las demás están presentes, no su relevancia absoluta. Variables que miden dimensiones similares tienden a repartir su poder explicativo, reduciendo el coeficiente individual sin que ello implique irrelevancia económica.

Evidencia empírica

Agarwal et al. (2015) analizan millones de cuentas de crédito y encuentran que el patrón de pago tiene alto poder predictivo del default, aunque este efecto se concentra principalmente en la distinción entre pago mínimo y no pago — es decir, en la frontera del incumplimiento — más que en la diferencia entre pago parcial y pago completo. Esto es consistente con que el signo negativo de la variable sea económicamente correcto y su contribución al score sea positiva, aunque menor en relación a variables de flujo financiero estructural como el ahorro y la cobertura de liquidez.

"Payment patterns — whether borrowers pay minimum, partial, or full balances — are among the most predictive features of subsequent default" (Agarwal, Chomsisengphet, Mahoney & Stroebe, 2015, QJE, Vol. 130, No. 1).

VII. CONCLUSIONES

Este trabajo presentó el desarrollo de un modelo de scoring de riesgo crediticio interpretable, construido como combinación lineal de ratios financieros siguiendo la lógica metodológica del Z-Score de Altman, y aplicado a un dataset de 100,000

observaciones mensuales correspondientes a 12,500 clientes. El proceso abarcó cuatro etapas secuenciales: limpieza y verificación del dataset, ingeniería de características, optimización de pesos y evaluación del modelo final.

La etapa de limpieza demostró que los datos crediticios reales contienen inconsistencias estructurales significativas que, de no ser tratadas adecuadamente, comprometen la estabilidad y validez de cualquier modelo posterior. Las estrategias diferenciadas por variable —imputación por moda intracliente, forward fill temporal, winsorización por percentiles e invalidación de valores estructuralmente imposibles— permitieron obtener un dataset completamente íntegro sin eliminar ningún registro, preservando la totalidad de la información disponible.

La construcción de ratios financieros como variables de entrada resolvió el problema de escala inherente a los modelos lineales y produjo variables económicamente interpretables, comparables entre clientes de distintos niveles de ingreso y calculables en tiempo real sin dependencia de estadísticas del conjunto de entrenamiento. La transformación logarítmica aplicada a R3 estabilizó su distribución sin comprometer su interpretabilidad.

Se implementaron tres métodos de optimización numérica —Monte Carlo, Evolución Diferencial y Recocido Dual— sobre una partición rigurosa 60/20/20 que garantizó la ausencia de data leakage en todas las etapas. El método de Recocido Dual fue seleccionado como modelo final al presentar el mejor desempeño en el conjunto de validación.

El modelo final alcanzó una exactitud del 77.75% y un ROC-AUC de 0.7478 en el conjunto de prueba, superando en 6.75 puntos porcentuales el baseline de clasificación trivial. La estadística KS de 0.489 confirma un buen poder discriminante según los estándares de la industria financiera. La tasa de default predicha (29.07%) reproduce con alta fidelidad la tasa real observada (29.00%), evidenciando una calibración agregada prácticamente perfecta gracias al mecanismo de umbral proporcional.

El análisis de contribuciones reveló que Credit_Mix_final, R3_log y R5_Interest_Stress concentran el 83.8% de la contribución total al score, siendo la estructura del crédito el factor dominante con el 38.8% de la contribución. Este resultado es consistente con la literatura de credit scoring, donde la diversificación y calidad del portafolio crediticio constituyen los determinantes más informativos del perfil de riesgo individual. La curva de ganancias acumuladas mostró que revisando únicamente el 30% más riesgoso del portafolio es posible identificar el 63.5% de todos los defaults, con un lift máximo de 2.30 en el tercer decil.

Desde el punto de vista metodológico, este trabajo demuestra que la tensión entre capacidad predictiva e interpretabilidad no es irresoluble. Un modelo lineal con variables bien construidas, pesos económicamente restringidos y optimización numérica rigurosa puede alcanzar un desempeño competitivo manteniendo transparencia completa, auditabilidad ante reguladores y coherencia con la teoría financiera. Esta combinación de propiedades lo hace especialmente adecuado para su adopción en entornos institucionales donde la explicabilidad de las decisiones crediticias es un requisito regulatorio y no una preferencia opcional.

Como trabajo futuro, sería relevante explorar la incorporación de variables macroeconómicas que capturen el entorno sistémico del riesgo, evaluar la estabilidad temporal del modelo ante cambios en el ciclo crediticio, y comparar su desempeño directamente contra modelos de machine learning interpretable como árboles de decisión o regresión logística regularizada bajo las mismas condiciones experimentales.

BIBLIOGRAFÍA

- Agarwal, S., Chomsisengphet, S., Mahoney, N., & Stroebel, J. (2015). Regulating consumer financial products: Evidence from credit cards. *Quarterly Journal of Economics*, 130(1), 111-164.
- Agarwal, S., Chomsisengphet, S., Mahoney, N., & Stroebel, J. (2018). Do banks pass through credit expansions to consumers who want to borrow? *The Quarterly Journal of Economics*, 133(1), 129-190.
- Avery, R. B., Calem, P. S., & Canner, G. B. (2003). An overview of consumer data and credit reporting. *Federal Reserve Bulletin*, 89, 47-73.
- Bertaut, C., & Haliassos, M. (2006). Credit cards: Facts and theories. *Oxford Handbook of Household Finance*. Oxford University Press.
- Bhutta, N., & Keys, B. J. (2016). Interest rates and equity extraction during the housing boom. *American Economic Review*, 106(7), 1742-1774.
- Cameron, A. C., & Trivedi, P. K. (2005). *Microeconometrics: Methods and Applications*. Cambridge University Press.
- Campbell, J. Y. (2006). Household finance. *Journal of Finance*, 61(4), 1553-1604.
- Dynan, K., Elmendorf, D., & Sichel, D. (2012). The evolution of household income volatility. *The B.E. Journal of Economic Analysis & Policy*, 12(2), 1-42.
- Greene, W. H. (2018). *Econometric Analysis* (8th ed.). Pearson Education.

- Gross, D. B., & Souleles, N. S. (2002). Do liquidity constraints and interest rates matter for consumer behavior? *Quarterly Journal of Economics*, 117(1), 149-185.
- Lusardi, A., & Mitchell, O. S. (2014). The economic importance of financial literacy: Theory and evidence. *Journal of Economic Literature*, 52(1), 5-44.
- Murcia, A., & Zárate, H. (2012). Determinants of household default in Colombia. *Borradores de Economía* No. 721, Banco de la República.
- Siddiqi, N. (2012). *Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring*. John Wiley & Sons.
- Bank for International Settlements (BIS). (2021). Household debt and consumption: New evidence from micro data. Working Paper No. 942.
- Consumer Financial Protection Bureau (CFPB). (2022). The consumer credit card market. Annual report. CFPB.
- FICO. (2022). Understanding FICO Scores: The science behind the number. Fair Isaac Corporation.
- Haughwout, A., Lee, D., Scally, J., & van der Klaauw, W. (2019). Just Released: Delinquency Is Increasingly in the Cards for Maxed-Out Millennials. Federal Reserve Bank of New York Liberty Street Economics.
- International Monetary Fund (IMF). (2019). Household debt and financial stability. Working Paper WP/19/182. IMF.
- Moody's Analytics. (2023). Consumer credit risk modeling: Methodology and best practices. Moody's Analytics Credit Research.
- S&P Global. (2020). U.S. consumer ABS credit performance overview and analytical framework. S&P Global Ratings.